Dataset Datos Históricos de Ortelana Textil

Introducción

El **Dataset Datos Históricos de Ortelana Textil** es un conjunto de datos diseñado para representar la evolución histórica de la comercialización de productos textiles en una red de sucursales distribuidas geográficamente.

El dataset fue concebido con fines educativos y de investigación, permitiendo trabajar sobre problemáticas de modelado de datos, bases de datos relacionales, análisis estadístico, inteligencia artificial, recuperación aumentada por generación (RAG), sistemas basados en embeddings y agentes inteligentes.

La información se organiza siguiendo una estructura multidimensional en la que cada registro representa la actividad comercial de una determinada tela durante un período de tiempo específico.

Organización general

Cada registro del dataset describe las ventas de una tela determinada en una sucursal específica durante un año calendario.

Los valores almacenados representan cantidades comercializadas, expresadas en metros lineales de tela.

La interpretación temporal de dichas cantidades depende del formato de reporte asociado a cada registro. Una misma sucursal puede utilizar distintos formatos en diferentes años o para distintas líneas de productos, según las modalidades de consolidación y reporte vigentes en cada período.

Componentes principales

Sucursal

Identifica la sucursal responsable del reporte.

Cada sucursal constituye una unidad operativa independiente dentro de la organización.

Ejemplos:

- Central Buenos Aires
- Córdoba
- Rosario
- Mendoza
- Mar del Plata

Año

Indica el año calendario al que corresponde la información reportada.

Línea Textil

Representa una agrupación comercial de productos textiles con características similares.

Ejemplos:

- Indumentaria
- Alta Costura
- Tapicería
- Hogar
- Industrial
- Técnicos

Tela
Identifica el producto textil específico sobre el cual se registran las cantidades comercializadas.

Las telas se organizan jerárquicamente dentro de una línea textil y pertenecen a distintas familias de productos que los agrupan: las lonas, las sedas, etc. Dentro de cada familia caen las telas específicas, ya cada una con su detalle.

Ejemplos:

- Denim 12 oz
- Denim 8 oz elastizado
- Gabardina clásica
- Seda satinada
- Chenille antimanchas
- Lona PVC
- Geotextil vial
- Mediasombra

Para más información ver más adelante la Taxonomía de Productos.

Formato de reporte

Las sucursales pueden informar sus ventas utilizando distintos niveles de agregación temporal.

El formato utilizado se indica mediante el campo **FormatoReporte**.

M – Mensual

Las cantidades representan ventas correspondientes a cada uno de los doce meses del año.

B – Bimestral

Las cantidades representan ventas agrupadas en períodos de dos meses.

S – Semestral

Las cantidades representan ventas agrupadas en dos semestres anuales.

C – Temporadas comerciales

Las cantidades representan ventas agrupadas según las dos temporadas comerciales utilizadas por la empresa:

- Otoño–Invierno
- Primavera–Verano

Cantidades comercializadas

El dataset contiene una serie de campos numéricos destinados a almacenar las cantidades vendidas durante cada período.

El significado de cada campo depende del formato de reporte asociado al registro.

Por ejemplo, el mismo campo puede representar:

- Enero, en un reporte mensual;
- Enero-Febrero, en un reporte bimestral;

- Primer semestre, en un reporte semestral;
- Otoño-Invierno, en un reporte por temporadas.

Esta característica obliga a interpretar correctamente el contexto de cada registro antes de realizar procesos de agregación o análisis.

Cuando un formato utiliza períodos agregados, la cantidad correspondiente se registra al cierre del período informado. Por ejemplo, en un reporte bimestral la suma de ventas de enero y febrero se almacena en el campo asociado a febrero, mientras que la suma de marzo y abril se registra en el campo asociado a abril. De manera análoga, en los formatos semestrales y por temporadas comerciales, cada valor se registra en el campo correspondiente al último mes o al cierre de la temporada informada. Esta convención permite representar las ventas acumuladas al finalizar cada período manteniendo una estructura uniforme de almacenamiento independientemente de la granularidad temporal empleada por cada sucursal.

Taxonomía de productos

Las telas se organizan siguiendo una estructura jerárquica:

Línea Textil → Familia → Tela

Ejemplo:

Indumentaria
→ Denims
→ Denim 12 oz

Indumentaria
→ Gabardinas
→ Gabardina elastizada

Tapicería
→ Chenilles
→ Chenille antimanchas

Industrial
→ Lonas
→ Lona PVC

Esta organización facilita procesos de clasificación, agrupamiento y análisis comparativo.

Catálogo semántico de productos

Además del dataset histórico, Ortelana dispone de un catálogo semántico independiente asociado a cada tela.

Cada producto posee una descripción rica que incluye:

- características técnicas;
- composición y materiales predominantes;
- aplicaciones recomendadas;
- observaciones comerciales;
- sinónimos regionales;
- etiquetas descriptivas;
- disponibilidad operativa.

La composición puede involucrar fibras de origen vegetal, animal, sintético o mezclas de ellas, permitiendo representar tanto materiales puros como tejidos compuestos de uso habitual en la industria textil.

Ejemplo conceptual:

Denim 12 oz

Etiquetas asociadas:

- jean
- vaquero
- mezclilla
- ropa de trabajo

Un producto del catálogo puede representarse mediante un documento semántico como el siguiente:

```JSON
{
  "id": "IND-DEN-001",
  "descripcion_semantica": "Denim pesado de 12 oz, 100% algodón rígido con teñido índigo intenso. Presenta un tacto rústico y cuerpo firme, ideal para camperas y pantalones.",
  "metadatos": {
```

```
    "linea_textil": "indumentaria",
    "composicion": "algodón",
    "origen_fibra": "vegetal",
    "sucursal_disponible": "central_buenos_aires",
    "en_stock": true,
    "tags_regionales": [
      "jean",
      "vaquero",
      "mezclilla",
      "ropa de trabajo"
    ]
  }
}
```

Este catálogo puede utilizarse para tareas de búsqueda semántica, sistemas RAG, recomendadores y agentes conversacionales.

Relación entre datos históricos y catálogo semántico

Los registros históricos y los documentos semánticos se encuentran vinculados mediante un identificador único de tela.

Esto permite combinar consultas analíticas tradicionales con técnicas modernas de recuperación de información.

Por ejemplo:

- identificar la tela más vendida de una categoría;
- localizar productos adecuados para una necesidad específica;
- correlacionar comportamiento comercial con características técnicas;
- generar recomendaciones automáticas basadas en ventas históricas y conocimiento semántico.

El catálogo semántico no pretende normalizar exhaustivamente todas las características técnicas de los productos. Su objetivo es enriquecer la información histórica mediante descripciones, metadatos y etiquetas que permitan tareas de búsqueda, recomendación, clasificación y recuperación semántica de información.

Aplicaciones educativas

El dataset fue diseñado para permitir actividades relacionadas con:

- modelado conceptual;
- diagramas UML;
- diseño de bases de datos;
- SQL;
- procesos ETL;
- análisis exploratorio de datos;
- calidad de datos;
- minería de información;
- recuperación semántica;
- sistemas RAG;
- agentes basados en inteligencia artificial.

La coexistencia de información estructurada y semántica convierte al conjunto en un entorno adecuado para el estudio integrado de tecnologías tradicionales y modernas de gestión de información.

Alertas y Reglas Pedagógicas del Dataset

El diseño imita las imperfecciones recurrentes en sistemas distribuidos reales para elevar la dificultad del ejercicio académico:

1. Inconsistencia de Surtido Exprofeso: Aproximadamente entre un 10% y un 12% de las combinaciones anuales de Año-Tela-Sucursal han sido omitidas de manera deliberada en las filiales del interior para emular quiebres de stock históricos o problemas de distribución. Los alumnos deben ser capaces de realizar agregaciones sin asumir una matriz perfecta de registros.
2. Tratamiento Extremo de Nulos: El procesamiento del archivo requerirá el uso mandatorio de funciones de limpieza como COALESCE en entornos SQL, o bien métodos del tipo .fillna() o .dropna(subset=...) en arquitecturas de análisis con Python (Pandas).